

Aplicación de NumPy y Análisis Exploratorio de Datos para la Detección de Fraude Financiero

1. Introducción

En la actualidad, el análisis de datos se ha convertido en una herramienta fundamental para la toma de decisiones en diversos campos, especialmente en áreas como la Inteligencia Artificial, el Machine Learning y la Ciencia de Datos. El manejo eficiente de grandes volúmenes de información requiere herramientas especializadas que permitan procesar, analizar e interpretar los datos de manera rápida y precisa.

Dentro de este contexto, la biblioteca NumPy constituye una de las herramientas más importantes del ecosistema Python, debido a su capacidad para trabajar con arreglos multidimensionales y ejecutar operaciones matemáticas de alto rendimiento. Su utilización facilita el desarrollo de algoritmos de análisis de datos y constituye la base de múltiples bibliotecas empleadas en proyectos de Inteligencia Artificial.

El presente trabajo tiene como finalidad aplicar los conceptos fundamentales de NumPy mediante el desarrollo de ejercicios prácticos relacionados con la manipulación de arreglos, el cálculo de estadísticas descriptivas, la generación de datos sintéticos y el análisis exploratorio de datos asociados a la detección de fraude financiero.

2. Objetivos

2.1 Objetivo General

Aplicar las funcionalidades de la biblioteca NumPy para el procesamiento y análisis de datos, desarrollando competencias fundamentales para su utilización en proyectos de Ciencia de Datos e Inteligencia Artificial.

2.2 Objetivos Específicos

Comprender el funcionamiento de los arreglos multidimensionales en NumPy.

Realizar operaciones matemáticas y estadísticas sobre conjuntos de datos.

Analizar medidas de tendencia central y dispersión.

Generar datos sintéticos mediante distribuciones probabilísticas.

Interpretar visualizaciones gráficas para identificar patrones en los datos.

Evaluar variables asociadas a posibles eventos de fraude financiero.

Karol Caicedo
Luisa Fernanda
Elkin Andres Chalarca
Dairon Valencia Campaz



Unipacifico - Ingeniería de sistemas

3. Marco Teórico

NumPy

NumPy (Numerical Python) es una biblioteca de código abierto diseñada para realizar cálculos numéricos de manera eficiente en Python. Su principal característica es la implementación de estructuras de datos denominadas ndarray, las cuales permiten almacenar y manipular grandes cantidades de información numérica de forma optimizada.

```
In [ ]: import numpy as np
```

Entre sus principales ventajas se encuentran:

Mayor velocidad de procesamiento frente a las listas tradicionales de Python.

Soporte para arreglos multidimensionales.

Amplia variedad de funciones matemáticas y estadísticas.

Integración con bibliotecas como Pandas, Matplotlib, Scikit-Learn y TensorFlow.

Estadística Descriptiva

La estadística descriptiva comprende un conjunto de técnicas utilizadas para resumir y describir las características principales de un conjunto de datos. Entre las medidas más importantes se encuentran:

Media aritmética.

Valor máximo.

Valor mínimo.

Desviación estándar.

Estas medidas permiten comprender la distribución y variabilidad de los datos analizados.

`np.mean()` (**Promedio/Media**): Calcula el valor central de los datos, sumando todos los elementos y dividiéndolos por la cantidad total.

`np.max()` y `np.min()` (**Máximo y Mínimo**): Identifican los valores extremos del conjunto de datos, lo que nos ayuda a conocer el rango completo de nuestra información.

`np.std()` (**Desviación Estándar**): Mide qué tan dispersos están los datos con respecto al promedio.

```
] import numpy as np

# Definición del arreglo de datos según el taller
datos = np.array([12, 18, 20, 25, 30, 35, 40])

# Cálculo e impresión de las estadísticas descriptivas
print("---- Estadísticos Descriptivos ----")
print(f"Promedio (Media): {np.mean(datos):.2f}")
print(f"Valor Máximo: {np.max(datos)}")
print(f"Valor Mínimo: {np.min(datos)}")
print(f"Desviación Est.: {np.std(datos):.2f}")
```

Unipacífico - Ingeniería de sistemas
Análisis Exploratorio de Datos

El análisis exploratorio de datos (EDA) consiste en examinar y visualizar la información disponible con el propósito de identificar patrones, tendencias, anomalías y relaciones entre variables antes de construir modelos predictivos.

4. Desarrollo de la Actividad

Inicialmente se realizó una investigación sobre las características y aplicaciones de NumPy dentro del ámbito de la Ciencia de Datos. Posteriormente se desarrollaron ejercicios prácticos enfocados en la creación y manipulación de arreglos multidimensionales.

Se trabajó con matrices de diferentes dimensiones utilizando técnicas de indexación para acceder a elementos específicos y verificar la correcta organización de la información.

Posteriormente se aplicaron funciones estadísticas para calcular medidas descriptivas tales como el promedio, el valor máximo, el valor mínimo y la desviación estándar de diversos conjuntos de datos.

Finalmente, se generaron datos sintéticos mediante una distribución normal con el objetivo de simular escenarios similares a los encontrados en aplicaciones reales de análisis de datos e Inteligencia Artificial.

Como complemento, se desarrolló un análisis exploratorio sobre un conjunto de datos relacionado con transacciones financieras y detección de fraude, utilizando herramientas de visualización gráfica para identificar posibles patrones de comportamiento.

CONTEXTO

Un banco desea identificar patrones asociados a transacciones potencialmente fraudulentas.

<i>Variable</i>	<i>Tipo</i>
<i>Valor de Transacción</i>	Numérica
<i>Hora del Día</i>	Numérica
<i>Número de Transacciones Diarias</i>	Numérica
<i>Distancia Geográfica</i>	Numérica
<i>Fraude</i>	Sí/No

Unipacífico - Ingeniería de sistemas

5. Resultados y Análisis

Análisis de Variables

El estudio exploratorio permitió identificar comportamientos diferenciados entre las transacciones legítimas y aquellas clasificadas como fraudulentas.

Out[]:	Valor_Transaccion	Hora_Del_Dia	Numero_Transacciones_Diarias	Distancia_Geografica	Fraude
0	3543824.17	14	8	14.70	NO
1	2413518.27	11	2	197.76	NO
2	1896158.07	15	12	303.09	NO
3	3528370.98	12	13	298.86	NO
4	1251133.53	14	7	396.48	NO
...	...	...	...	...	...
495	3603810.88	14	18	248.02	SI
496	541827.86	16	17	6.36	SI
497	708692.51	11	19	496.21	SI
498	1325782.18	11	9	335.73	NO
499	1339826.98	13	4	158.46	NO

Valor de la Transacción

Se observó que las transacciones fraudulentas presentan una mayor concentración en montos elevados. Aunque existe superposición entre ambas categorías, los valores altos parecen incrementar la probabilidad de fraude.

Métrica Estadística	Valor Registrado	Interpretación Operativa
Count (Cuento)	500.00	Muestra completa y homogénea en registros.
Mean (Media)	2,543,087.79	El monto promedio general por transacción está en el rango de los 2.5 millones.
Std (Desv)	1,380,537.38	Alta dispersión. Existen variaciones significativas entre los montos de una transacción a otra.
Min (Mínimo)	22,949.17	Transacción de menor valor registrada en el dataset.
25% (Q1)	1,377,880.32	El 25% de las transacciones son de montos bajos/moderados (menores a 1.37M).
50% (Mediana)	2,630,200.96	El punto medio exacto de las operaciones. Al estar muy cerca de la media, sugiere una distribución simétrica.
75% (Q3)	3,714,167.43	El 75% de las operaciones no superan los 3.71 millones.
Max (Máximo)	4,988,486.15	Monto máximo transaccionado dentro de la muestra.

Hora del Día

La distribución de las transacciones a lo largo del día mostró un comportamiento relativamente uniforme. No se identificaron horarios específicos con una concentración significativa de actividades fraudulentas.

Unipacifico - Ingeniería de sistemas

Métrica Estadística	Valor Registrado	Interpretación Horaria (Reloj)
Count (Cuento)	500.00	Muestra completa de 500 registros.
Mean (Media)	11.91	El promedio de ocurrencia ronda las 11:54 AM.
Std (Desv)	2.61	Dispersión baja. La mayoría de las operaciones se agrupan en un bloque horario compacto.
Min (Mínimo)	8.00	La actividad registrada inicia exactamente a las 08:00 AM.
25% (Q1)	10.00	El 25% de las transacciones se realizan entre las 8:00 AM y las 10:00 AM.
50% (Mediana)	12.00	El 50% de las transacciones ocurren antes del mediodía (12:00 PM).
75% (Q3)	14.00	El 75% de las transacciones se han completado para las 02:00 PM.
Max (Máximo)	16.00	La última transacción registrada ocurre a las 04:00 PM (16:00).

Número de Transacciones Diarias

Los registros asociados a fraude mostraron una tendencia a concentrarse en usuarios con un mayor número de transacciones realizadas durante el mismo día, lo que podría indicar comportamientos atípicos o actividades sospechosas.

Métrica Estadística	Valor Registrado	Interpretación de Frecuencia
Count (Cuento)	500.00	Datos disponibles para los 500 casos analizados.
Mean (Media)	10.68	En promedio, un usuario genera cerca de 11 transacciones al día.
Std (Desv)	5.65	Dispersión moderada, indicando perfiles de usuario con variada intensidad de uso.
Min (Mínimo)	1.00	El usuario menos activo realizó solo 1 transacción en el día.
25% (Q1)	6.00	El 25% de los usuarios realiza 6 o menos transacciones diarias.
50% (Mediana)	11.00	El 50% de la muestra realiza hasta 11 operaciones por día.
75% (Q3)	15.00	El 75% de los clientes se mantiene en un umbral de hasta 15 transacciones.
Max (Máximo)	20.00	Intensidad máxima de uso: 20 transacciones diarias.


Distancia Geográfica

Esta variable presentó una de las diferencias más relevantes entre las categorías analizadas. Las transacciones fraudulentas tienden a registrarse a mayores distancias geográficas, mientras que las transacciones legítimas se encuentran generalmente dentro de rangos más reducidos.

Unipacifico - Ingeniería de sistemas

Métrica Estadística	Valor Registrado	Interpretación Geográfica
Count (Cuento)	500.00	500 distancias calculadas correspondientes a las transacciones.
Mean (Media)	243.69	La distancia promedio general se sitúa en 243.69 unidades (ej. km).
Std (Desv)	139.02	Alta dispersión, evidenciando un amplio radio de movilidad de los clientes.
Min (Mínimo)	0.17	Operación realizada prácticamente en el lugar de residencia habitual.
25% (Q1)	122.79	El 25% de las transacciones ocurren a distancias cortas (menos de 122.79 unidades).
50% (Mediana)	240.38	El 50% de las operaciones se efectúan a una distancia menor o igual a 240.38 unidades.
75% (Q3)	347.53	El 75% de los eventos ocurren dentro de un radio de 347.53 unidades.
Max (Máximo)	497.74	Distancia máxima registrada desde el punto de origen de la cuenta (cerca a 500 unidades).

Interpretación del Pairplot




Unipacifico - Ingeniería de sistemas

El Pairplot permitió visualizar simultáneamente las relaciones entre todas las variables numéricas del conjunto de datos. Los gráficos evidenciaron que no existe una relación lineal fuerte entre las variables analizadas; sin embargo, sí se identificaron tendencias importantes.

Las variables Valor_Transacción, Número_Transacciones_Diarias y Distancia_Geográfica mostraron una mayor capacidad para diferenciar entre transacciones fraudulentas y legítimas. Por el contrario, la variable Hora_Del_Día presentó una baja capacidad discriminatoria.

Estos resultados sugieren que la detección de fraude no depende de una única característica, sino de la combinación de múltiples variables que, analizadas conjuntamente, permiten identificar patrones de comportamiento anómalos.



6. Conclusiones

La realización de este trabajo permitió comprender la importancia de NumPy como herramienta fundamental para el procesamiento eficiente de datos numéricos en Python. Las actividades desarrolladas facilitaron el aprendizaje de conceptos relacionados con arreglos multidimensionales, operaciones matemáticas y análisis estadístico.

Asimismo, el análisis exploratorio realizado demostró que las técnicas de visualización constituyen una herramienta valiosa para identificar patrones y tendencias dentro de los datos. En particular,

Karol Caicedo
Luisa Fernanda
Elkin Andres Chalarca
Dairon Valencia Campaz



Unipacífico - Ingeniería de sistemas
las variables relacionadas con el valor de las transacciones, la frecuencia de operaciones y la distancia geográfica mostraron una influencia significativa en la identificación de posibles eventos de fraude.

Finalmente, se concluye que la detección de fraude financiero requiere la evaluación conjunta de múltiples factores y que las técnicas de análisis de datos e Inteligencia Artificial representan herramientas fundamentales para mejorar la precisión de los sistemas de detección y prevención de actividades fraudulentas.

7. Referencias Bibliográficas

Harris, C. R., Millman, K. J., Van Der Walt, S. J., et al. (2020). Array programming with NumPy. Nature, 585(7825), 357-362.

McKinney, W. (2022). Python for Data Analysis. O'Reilly Media.

VanderPlas, J. (2023). Python Data Science Handbook. O'Reilly Media.

Documentación oficial de NumPy: <https://numpy.org/>

Documentación oficial de Pandas: <https://pandas.pydata.org/>